Rethinking the Inception Architecture for Computer Vision

저자	Christian Szegedy, Vincent Vanhoucke, Sergey Ioffe, Jonathon Shlens
주요내용 요약	이 논문은 컴퓨터 비전을 위한 Inception 아키텍처를 재고하고 개선된 Inception-v2(그리고 궁극적으로 Inception-v3) 모델을 제시한다. 주요 목표는 효율적인 연산 비용과 적은 파라미터 수를 유지하면서 모델의 품질을 높이는 것이다.
PDF/Citation	https://arxiv.org/pdf/1512.00567
상태	요약완료
연구 형태	Original Research
키워드	Convolutional Networks, Inception Architecture

1. 배경 및 기존 문제점

컴퓨터 비전 분야에서 컨볼루션 신경망은 최첨단 성능을 달성하는 핵심 기술로 자리 잡고 있다. 2014년 이후로 매우 깊은 신경망들이 성능 향상을 견인했지만, 모델의 크기와 계산 비용 증가는 필연적으로 발생한다. 그럼에도 불구하고, 모바일 비전이나 빅데이터 시나리오와 같이 계산 효율성과 낮은 파라미터 수가 중요한 응용 분야들이 존재한다.

기존의 VGGNet은 높은 성능을 보였지만, 평가에 많은 계산량이 요구되는 단점이 있었다. 반면, GoogLeNet의 Inception 아키텍처는 제한된 컴퓨팅 예산에서도 좋은 성능을 내도록 설계되었으며, AlexNet대비 파라미터 수를 12배 줄이는 성과를 보였다. 하지만 Inception 아키텍처는 구조가 복잡하여 네트워크를 변경하거나 확장하기 어렵다는 문제점을 가지고 있다. 특히, 단순히 필터 크기를 늘리는 방식으로 스케일 업(scale up)하면 계산 비용이 기하급수적으로 증가하여 효율성을 크게 저해할 수 있다. 또한, GoogLeNet의 설계 결정에 대한 명확한 설명이 부족하여 새로운 사용 사례에 맞게 효율성을 유지하며 아키텍처를 수정하기

어려웠다. 따라서, 계산 비용을 효율적으로 사용하면서 모델을 확장하고 성능을 개선할 수 있는 새로운 방법론의 필요성이 대두되었다.

2. 핵심 아키텍처 특징

이 논문은 기존 Inception 아키텍처의 효율성을 개선하고 스케일 업하기 위한 여러 원칙과 방법론을 제시하며, 이를 'Inception-v2' 및 'Inception-v3' 아키텍처에 통합한다.

- **일반 설계 원칙:**
  - 네트워크 초반부에 표현 병목 현상(representational bottleneck)을 피한다.
  - 네트워크 내에서 높은 차원의 표현(activations)을 활용하여 더 분리된 특징을 학습하고 학습 속도를 높인다.
  - 낮은 차원에서의 공간적 집계(spatial aggregation)를 수행해도 표현력 손실이 적으며, 오히려 학습을 촉진할 수 있다고 본다.
  - 네트워크의 **넓이(width)와 깊이(depth)를 균형 있게** 조절하여 최적의 성능을 달성한다.
- **컨볼루션(Convolution) 분할 (Factorization):**
  - 큰 공간적 필터(예: 5x5를 여러 개의 작은 컨볼루션 레이어(예: 두 개의 3x3의 조합으로 분해하여 연산량과 파라미터 수를 줄인다.
  - nxn 컨볼루션을 nx1 컨볼루션과 1xn 컨볼루션의 비대칭 조합으로 분해하여 효율성을 더욱 높인다. 예를 들어, 3x3 컨볼루션을 3x1과 1x3으로 분해하면 33%의 연산 비용을 절감할 수 있다.

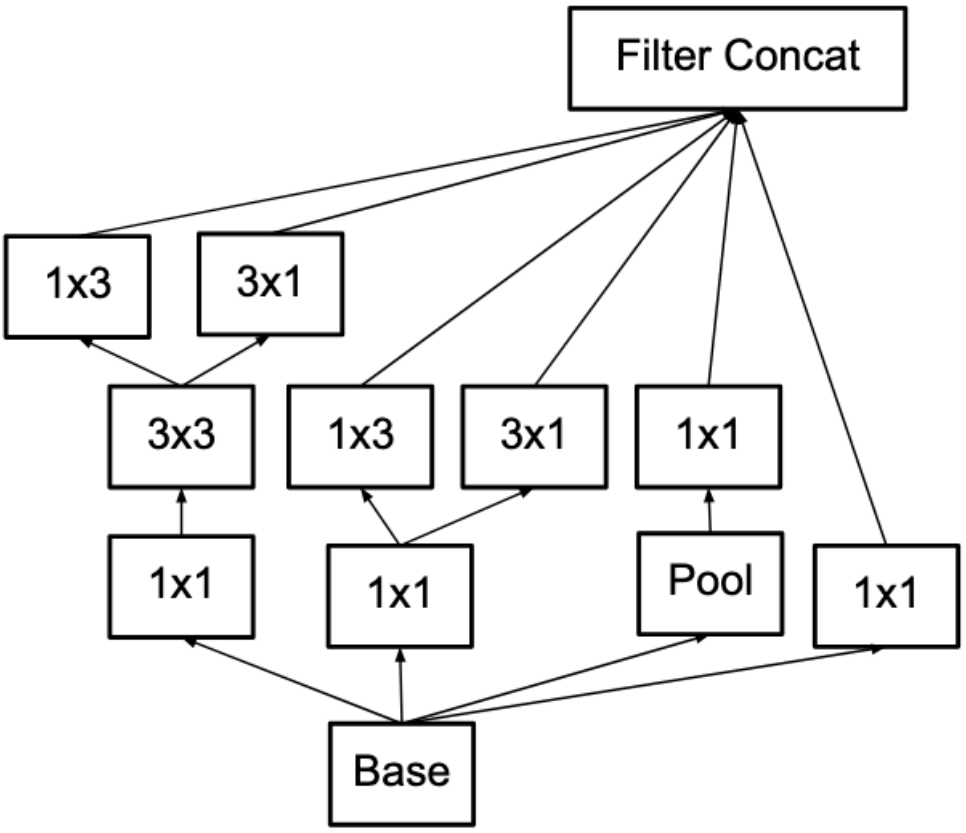

type	patch size/stride or remarks	input size
conv	$3\times3/2$	$299\times299\times3$
conv	$3\times3/1$	$149\times149\times32$
conv padded	$3\times3/1$	$147\times147\times32$
pool	$3\times3/2$	$147\times147\times64$
conv	$3\times3/1$	$73\times73\times64$
conv	$3\times3/2$	$71\times71\times80$
conv	$3\times3/1$	$35\times35\times192$
$3\times$Inception	As in figure 5	$35\times35\times288$
$5\times$Inception	As in figure 6	$17\times17\times768$
$2\times$Inception	As in figure 7	$8\times8\times1280$
pool	8×8	$8\times8\times2048$
linear	logits	$1\times1\times2048$
softmax	classifier	$1\times1\times1000$

- **효율적인 그리드 크기 축소 (Efficient Grid Size Reduction):**
  - 기존 풀링(pooling) 연산으로 인한 표현력 병목 현상을 피하기 위해, Stride 2의 풀링 레이어와 Stride 2의 컨볼루션 레이어를 병렬로 구성하고 이들의 출력을 연결(concatenate)하는 새로운 방법을 제안한다.
- **보조 분류기 (Auxiliary Classifiers)의 재해석:**
  - 기존에는 그래디언트 전달을 위해 사용되던 보조 분류기가 정규화(regularizer)로서의 역할을 더 중요하게 수행한다고 주장한다. 배치 정규화(Batch Normalization)나 드롭아웃(Dropout)을 적용했을 때 성능이 향상됨을 근거로 제시한다.
- **레이블 스무딩 (Label Smoothing Regularization - LSR):**
  - 모델의 과도한 자신감으로 인한 과적합(over-fitting)을 방지하기 위해, 원-핫(one-hot) 레이블 분포 대신 실제 레이블에 약간의 확률을 균등 분포와 같은 다른 레이블 분포로 분산시키는 정규화 기법을 사용한다.

3. 효과 및 한계점

제안된 방법론과 아키텍처 개선을 통해 Inception-v3는 다양한 측면에서 뛰어난 성과를 달성했다.

- **성능 향상:**
  - ILSVRC 2012 분류 챌린지에서 단일 프레임 평가 기준, Top-1 오류 21.2%, Top-5 오류 5.6%를 달성하며 당시 최첨단(state-of-the-art) 성능을 경신했다.
  - 4개 모델 앙상블과 다중 크롭 평가에서는 Top-5 오류 3.5%를 기록하며 기존 최고 기록을 경신했다.
- **계산 효율성:**
  - 기존 GoogLeNet 대비 연산 비용이 약 2.5배 증가하는 데 그쳤으며, VGGNet 과 같은 더 깊고 복잡한 모델들에 비해 훨씬 효율적이다.
  - 경쟁 모델인 He et al. 의 모델보다 6배 적은 계산량과 5배 적은 파라미터로 더 우수한 성능을 보였다.
- **하위 해상도 입력에서의 강건성:**
  - 낮은 해상도의 입력(예: 79x79 에서도 계산 비용을 일정하게 유지하면, 높은 해상도 입력(예: 299x299 와 비교했을 때 인식 성능 저하가 크지 않음을 입증했다. 이는 작은 객체 탐지와 같이 리소스가 제한된 환경에서의 활용 가능성을 보여준다.
- **한계점 및 향후 과제:**

- 논문에서 제시된 일반 설계 원칙들의 일반성과 도메인 간 유효성에 대한 추가적인 실험적 증거가 필요하다.
- 제안된 방법론들의 조합 효과에 대한 더 깊이 있는 분석이 이루어질 수 있다.
- 앙상블 기법을 적용했을 때의 성능 향상은 크지만, 실제 배포 시에는 단일 모델의 효율성과 성능 간의 trade-off를 고려해야 한다.

이 논문은 Inception 아키텍처의 복잡성을 효과적으로 관리하고, 계산 효율성을 높이면서도 성능을 극대화할 수 있는 실질적인 방법들을 제시하며, 컴퓨터 비전 모델 설계에 중요한 지침을 제공한다.