국민대학교
인공지능학회
X:AI

X:AI 1st Seminar 2026

Deep Residual Learning for Image Recognition

Kaiming He, Xiangyu Zhang, Shaoqing Ren, Jian Sun

CVPR 2016 | Microsoft Research

2026.04.09. X:AI 1st Seminar
국민대학교 인공지능학회 X:AI / 유가을 autumnqp@kookmin.ac.kr

CONTENTS

국민대학교
인공지능학회 X:AI

01 **Background**
왜 깊은 네트워크가 필요한가?

02 **Residual Learning**
H(x) 대신 F(x)를 학습하는 아이디어

03 **Shortcut Connection**
Identity vs Projection

04 **Plain vs ResNet**
아키텍처 비교

05 **ImageNet Results**
실험적 검증

06 **Bottleneck & Summary**
효율적 설계 및 결론

[01] Background

왜 깊은 네트워크가 필요한가?

■ **깊이(Depth)와 성능**

깊은 신경망 = 더 풍부한 Feature 표현 가능

VGG, GoogLeNet의 성공으로 Depth의 중요성 입증

■ **단순히 층을 쌓으면 될까?**

✕ **Degradation Problem**

깊이가 깊어질수록 Training Error가 오히려 증가

Overfitting이 아닌 최적화 자체의 문제!

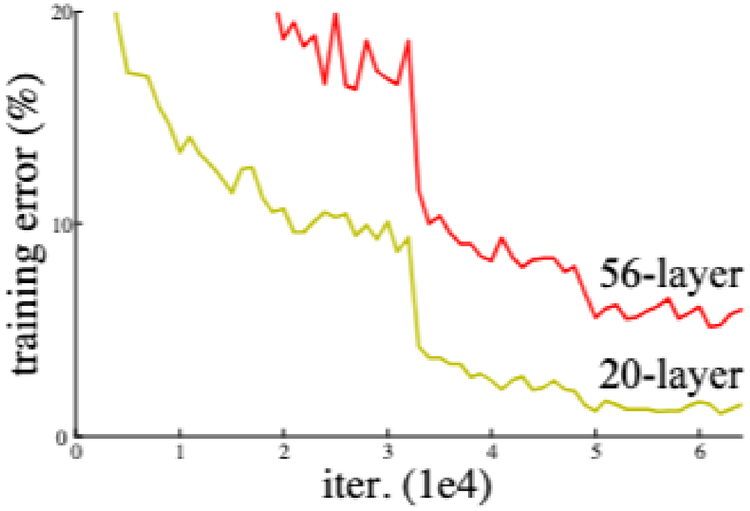

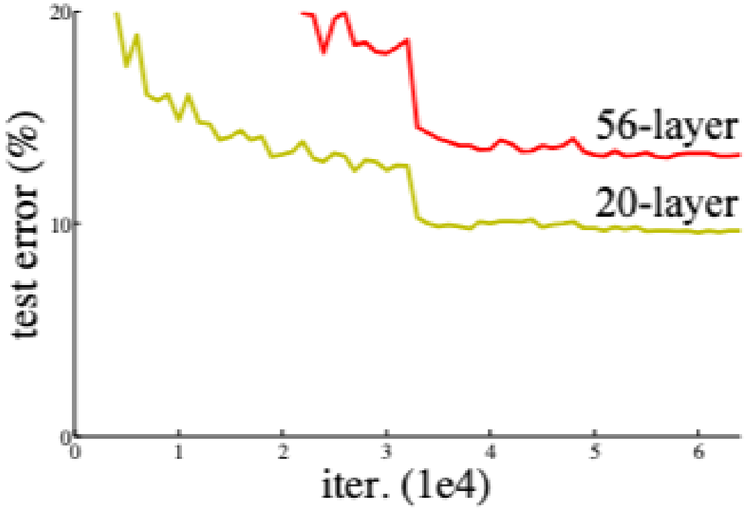

[02] Residual Learning

H(x) 대신 F(x)+x를 학습한다

■ **기존 방식**
각 레이어가 H(x)를 직접 학습

■ **잔차 학습 (Residual Learning)**
F(x) := H(x) - x 를 학습
출력 = F(x) + x (shortcut 연결로 구현)

■ **왜 더 쉬운가?**
최적 함수가 항등함수에 가깝다면,
F(x)를 0에 가깝게 만드는 것이 훨씬 쉬움

핵심 수식:
$y = F(x, \{W_i\}) + x$
$F(x) = W_2 \cdot \sigma(W_1 \cdot x)$

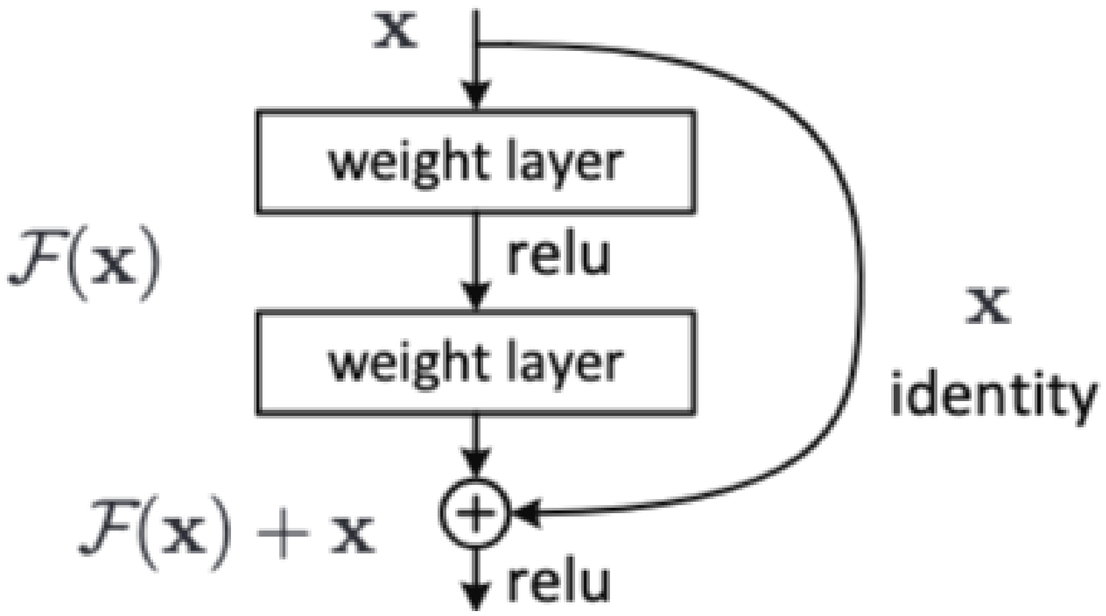

[03] Shortcut Connection

Identity vs Projection

■ **Identity Shortcut (차원이 같을 때)**

$y = F(x) + x$

파라미터·계산 비용 추가 없음 — 가장 이상적인 형태 (Eq. 1)

■ **Projection Shortcut (차원이 다를 때)**

$y = F(x) + W_s \cdot x$

1×1 Conv로 차원을 맞춤 — 파라미터 소량 증가 (Eq. 2)

두 방식 모두 Degradation 문제를 해결함을 실험으로 확인

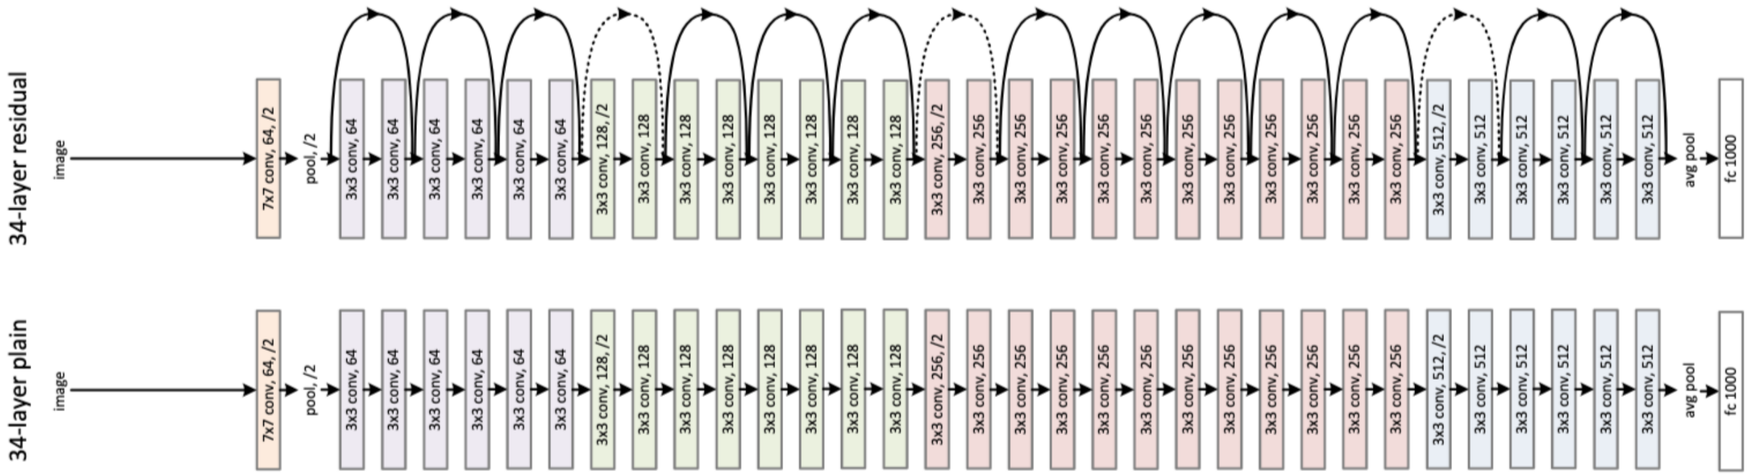

[04] Plain vs ResNet

아키텍처 비교 — 같은 FLOPs, 다른 결과

■ **Plain Network (34 레이어)**
VGG 철학 기반, 3×3 Conv 반복 — 층이 깊어질수록 오히려 성능 저하

■ **Residual Network (34 레이어)**
같은 구조 + Shortcut 추가 — 같은 FLOPs·파라미터로 더 높은 정확도

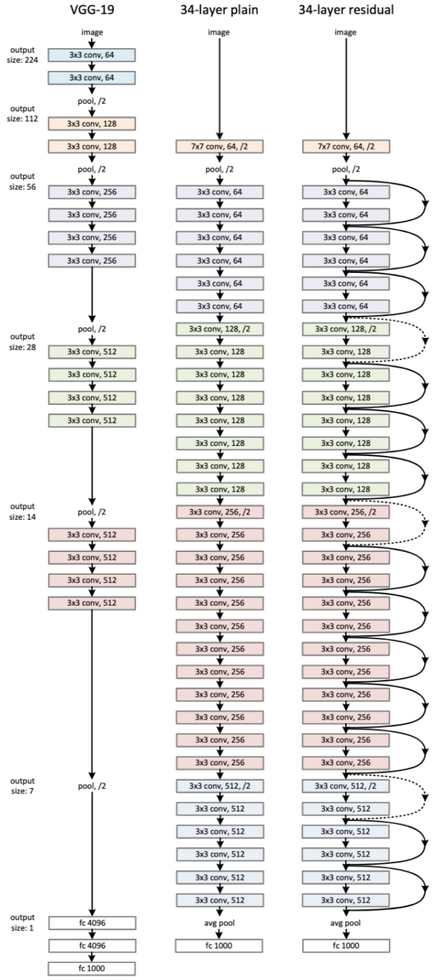

	plain	ResNet
18 layers	27.94	27.88
34 layers	28.54	**25.03**

[05] ImageNet Results

실험적 검증 — Plain vs ResNet 학습 곡선

❶ Plain-34 > Plain-18 에러 → Degradation 확인!
❷ ResNet-34 < ResNet-18 에러 → 잔차 학습이 Degradation을 역전시킴
❸ 18-layer에서도 ResNet이 Plain보다 빠르게 수렴

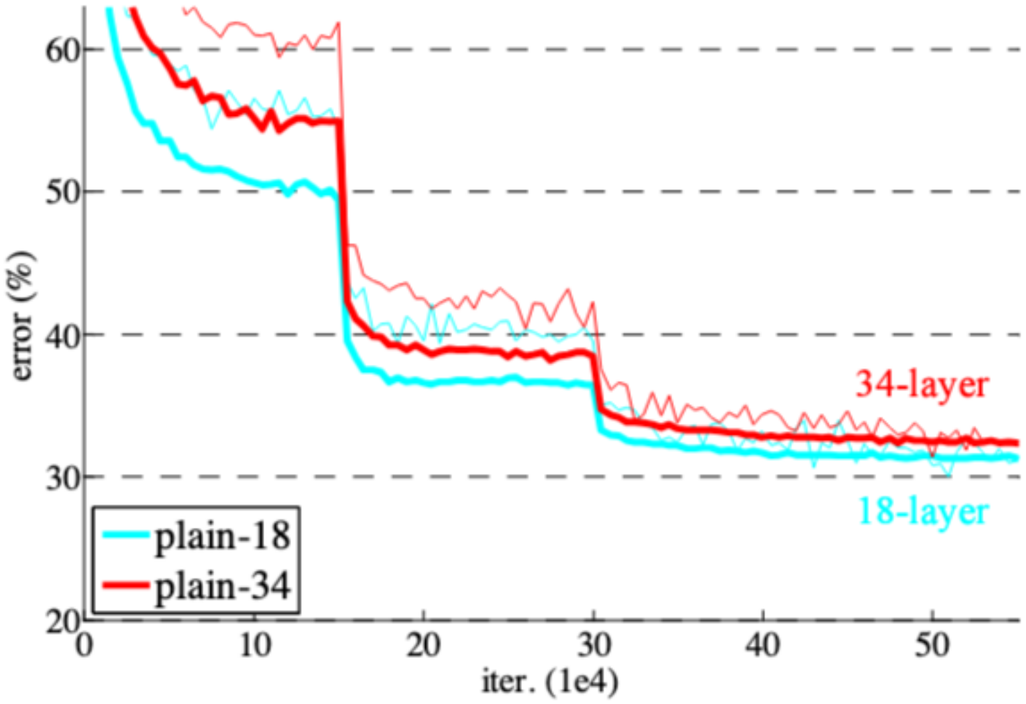

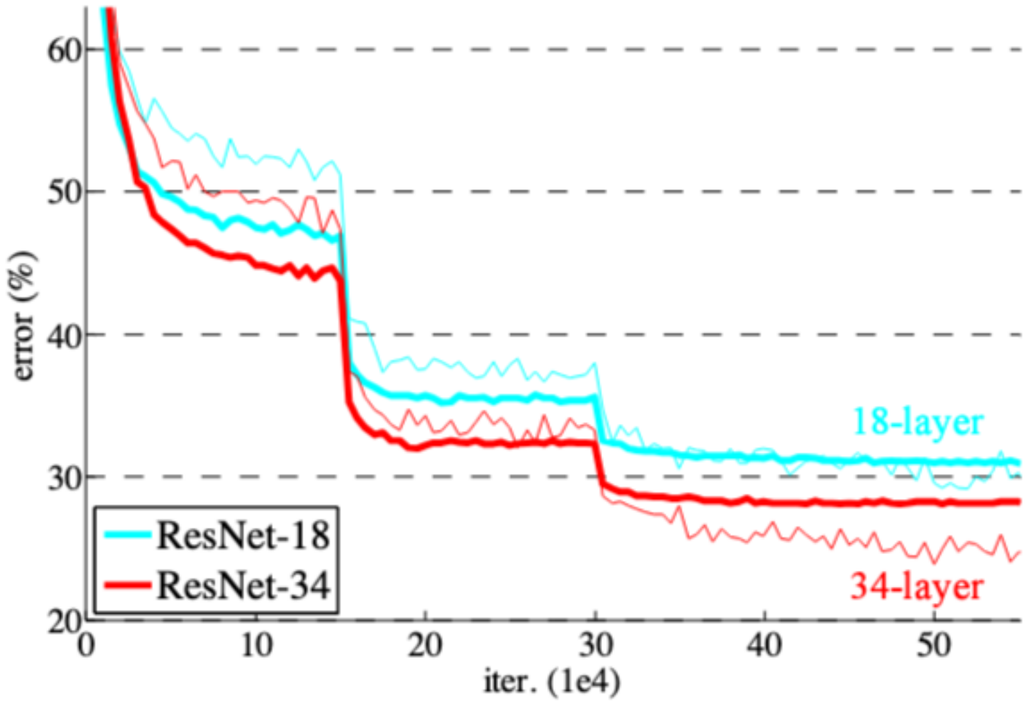

[05] ImageNet Results

Table 3 — 모델별 에러율 비교

■ **깊이가 깊어질수록 ResNet 성능 계속 상승**

ResNet-152: Top-5 Error 5.71% (단일 모델) / VGG-16: 9.33% 대비 대폭 향상

Ensemble: Top-5 Error 3.57% → ILSVRC 2015 분류 1위

model	top-1 err.	top-5 err.
VGG-16 [41]	28.07	9.33
GoogLeNet [44]	-	9.15
PReLU-net [13]	24.27	7.38
plain-34	28.54	10.02
ResNet-34 A	25.03	7.76
ResNet-34 B	24.52	7.46
ResNet-34 C	24.19	7.40
ResNet-50	22.85	6.71
ResNet-101	21.75	6.05
ResNet-152	**21.43**	**5.71**

[06] Bottleneck Design

효율적인 깊이 확장

■ **Basic Block (18 / 34 레이어용)**
3×3 Conv + 3×3 Conv

■ **Bottleneck Block (50 / 101 / 152 레이어용)**
1×1 Conv → 채널 축소 (차원 ↓)
3×3 Conv → 실질적인 합성곱 연산
1×1 Conv → 채널 복원 (차원 ↑)

■ **효과**
FLOPs는 비슷하면서 한 층 더 깊은 표현 가능
152 레이어도 VGG보다 낮은 연산량!

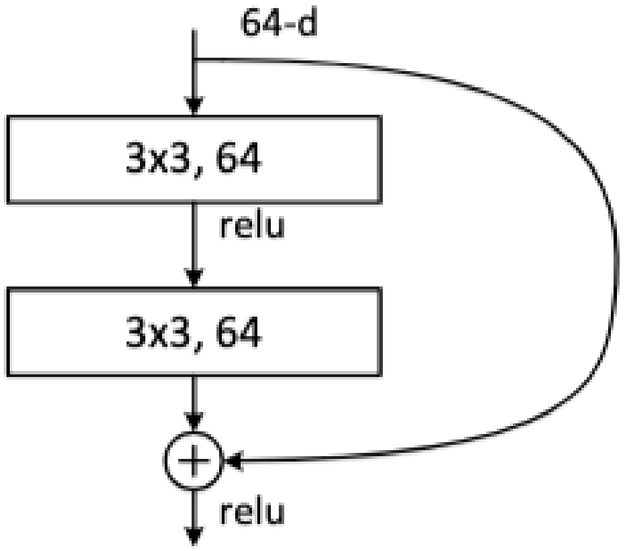

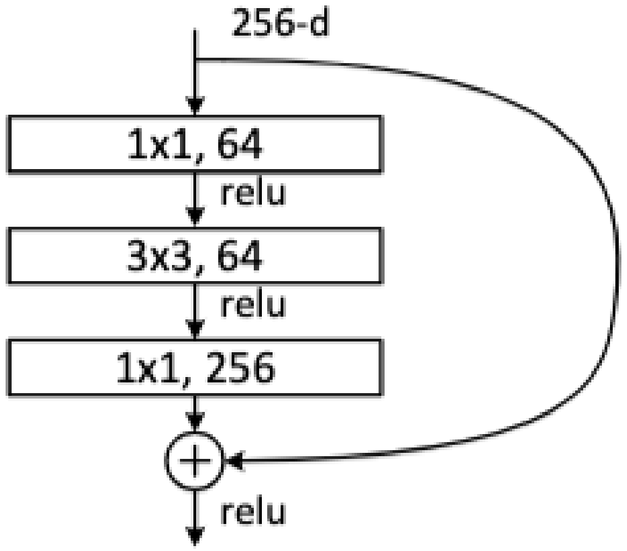

Limitations & Future Directions

한계 및 향후 방향

⚠ **한계**

1202 레이어에서 오히려 성능 감소
(데이터 규모 대비 모델이 지나치게 큼)
F(x)+x 범식에 대한 이론적 정당화 부족

→ **후속 연구 흐름**

Wide ResNet — 깊이 대신 폭(너비) 확대
DenseNet — 모든 레이어 연결
ResNeXt — 그룹 합성곱 도입
Pre-activation ResNet — BN·ReLU 순서 재조합
EfficientNet — 깊이/폭/해상도 함께 스케일
Transformer — 백본에도 Residual 구조 활용!

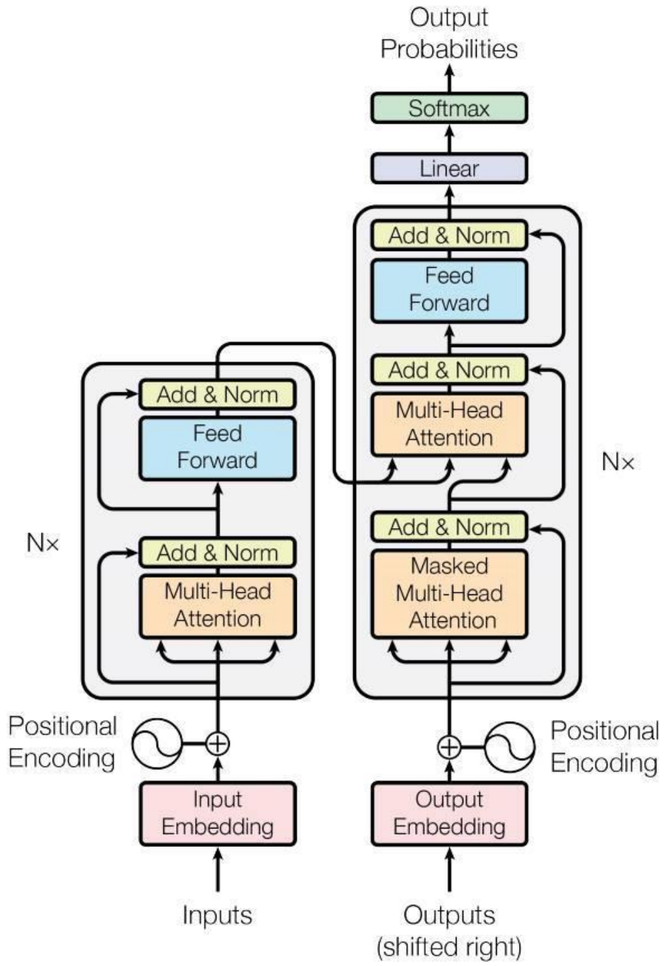

ResNet | Summary

Deep Residual Learning for Image Recognition — He et al., CVPR 2016

잔차 학습

H(x) 대신 F(x)를 학습
y = F(x) + x
(Shortcut 연결)

성능 결과

ResNet-152 Top-5 Error
5.71% (단일 모델)
3.57% (앙상블)

ILSVRC 2015

분류 / 탐지 / 로컬라이제이션
세그멘테이션
총 5개 부문 1위

X:AI 1st Seminar 2026

Thank You

국민대학교 경영정보학부
유가을
autumnqp@kookmin.ac.kr